HYDRAIA: SISTEMA HÍBRIDO DE APRENDIZADO PROFUNDO E ENSEMBLE DE MODELOS DE LINGUAGEM PARA ANÁLISE DE RISCO HÍDRICO NA MACROMETRÓPOLE PAULISTA

SOUSA, J. E. F.[1,*]; APPROBATO, C.[2]

[1] Centro Universitário das Faculdades Metropolitanas Unidas (FMU), Escola de Engenharia, Curso de Engenharia de Computação, RA 2022110106, São Paulo, SP, Brasil.

[2] Centro Universitário das Faculdades Metropolitanas Unidas (FMU), Departamento de Engenharias, São Paulo, SP, Brasil (orientador).

**CORRESPONDÊNCIA DO AUTOR. Centro Universitário das Faculdades Metropolitanas Unidas, Escola de Engenharia, São Paulo, SP, Brasil. Endereço de e-mail: 2022110106@fmu.edu.br (J. E. F. Sousa).*

RESUMO

A Macrometrópole Paulista concentra cerca de 22 milhões de habitantes abastecidos por sete sistemas produtores integrados, cuja infraestrutura, projetada sob premissas climáticas do século XX, vem sendo exposta a crises hídricas recorrentes, como as de 2014-2015 e 2020-2021, deflagradas por bloqueios atmosféricos e teleconexões oceânicas. A problemática investigada reside na incerteza da interpretação conjunta de dados climáticos e hidrológicos para a previsão do risco de escassez em curto e médio prazo: previsões meteorológicas informam quanto vai chover, mas não traduzem o impacto da precipitação no balanço hídrico dos reservatórios, enquanto Modelos de Linguagem de Grande Escala (LLMs), usados isoladamente, produzem imprecisões numéricas e alucinações. O objetivo geral do trabalho foi desenvolver o HydraIA, plataforma de software que unifica coleta de dados oficiais em tempo real, previsão hidrológica por aprendizado profundo e análise qualitativa de risco por ensemble de LLMs, produzindo relatórios técnicos com grau de confiança quantificado por validação cruzada. Quanto ao método, trata-se de pesquisa aplicada, de abordagem mista, conduzida por Pesquisa Experimental com prototipagem iterativa, complementada por Pesquisa Bibliográfica e Documental. A arquitetura implementada combina uma rede HydroLSTM bicamada treinada em 26 anos de séries diárias da SABESP (2000-2026), dois especialistas em nuvem (Gemini 2.5 Pro e GPT) e um sintetizador local (Mistral 7B Instruct) executado em GPU de consumo. Como resultados, o HydroLSTM alcançou MAE de 0,35 ponto percentual na validação e de 6,05 pontos percentuais no teste (RMSE de 7,53), o pipeline de compressão estatística reduziu em mais de 90% o consumo de tokens e o algoritmo de validação cruzada converteu divergências entre especialistas em ajustes explícitos de confiança, verificados em execuções com dados reais. Conclui-se que a integração entre redes recorrentes e ensembles de LLMs constitui solução tecnicamente viável, economicamente acessível e replicável para a análise de risco hídrico metropolitano.

Palavras-chave — *Previsão hidrológica; Aprendizado profundo; Modelos de Linguagem de Grande Escala; Validação cruzada; Macrometrópole Paulista.*

ABSTRACT

The São Paulo Macrometropolis concentrates around 22 million inhabitants

supplied by seven integrated water production systems whose infrastructure, designed under twentieth-century climate assumptions, has been exposed to recurrent water crises, such as those of 2014-2015 and 2020-2021, triggered by atmospheric blocking and oceanic teleconnections. The investigated problem lies in the uncertainty of jointly interpreting climate and hydrological data to forecast scarcity risk in the short and medium term: weather forecasts state how much it will rain but do not translate the impact of precipitation on reservoir water balance, while Large Language Models (LLMs), used in isolation, produce numerical inaccuracies and hallucinations. The general objective of this work was to develop HydraIA, a software platform that unifies real-time collection of official data, hydrological forecasting through deep learning and qualitative risk analysis through an ensemble of LLMs, producing technical reports with a confidence level quantified by cross-validation. Methodologically, this is applied research with a mixed approach, conducted through Experimental Research with iterative prototyping, complemented by bibliographic and documentary research. The implemented architecture combines a two-layer HydroLSTM network trained on 26 years of daily SABESP series (2000-2026), two cloud specialists (Gemini 2.5 Pro and GPT) and a local synthesizer (Mistral 7B Instruct) running on consumer GPU hardware. As results, the HydroLSTM achieved a MAE of 0.35 percentage points in validation and 6.05 percentage points in testing (RMSE of 7.53), the statistical compression pipeline reduced token consumption by more than 90% and the cross-validation algorithm converted divergences between specialists into explicit confidence adjustments, verified in runs with real data. It is concluded that the integration between recurrent networks and LLM ensembles constitutes a technically viable, economically accessible and replicable solution for metropolitan water risk analysis.

Key words — *Hydrological forecasting; Deep learning; Large Language Models; Cross-validation; São Paulo Macrometropolis.*

1 INTRODUÇÃO

1.1 Definição do tema de pesquisa

O presente trabalho apresenta o desenvolvimento do HydraIA, um sistema computacional híbrido para previsão climática e análise de risco hídrico voltado à Macrometrópole Paulista. O tema situa-se na interseção entre hidrologia urbana, aprendizado profundo aplicado a séries temporais e sistemas multiagente baseados em Modelos de Linguagem de Grande Escala (LLMs, do inglês Large Language Models).

Investigou-se como uma arquitetura híbrida edge-cloud, combinando redes Long Short-Term Memory (LSTM) treinadas em 26 anos de séries diárias da Companhia de Saneamento Básico do Estado de São Paulo (SABESP) com um ensemble de três LLMs (Gemini 2.5 Pro, GPT e Mistral 7B Instruct em execução local), pode produzir relatórios técnicos de risco hídrico com grau de confiança

quantificado por validação cruzada (HOCHREITER; SCHMIDHUBER, 1997; VASWANI et al., 2017; LEWIS et al., 2020). Este artigo dá continuidade ao pré-projeto apresentado à disciplina de Pré-Projeto Final de Curso em Engenharia, mantendo o tema e as diretrizes nele estabelecidos e reportando os resultados obtidos com o protótipo implementado.

1.2 Apresentação do cenário do tema

A gestão hídrica na Região Metropolitana de São Paulo (RMSP) é um dos maiores desafios da engenharia ambiental brasileira. Com cerca de 22 milhões de habitantes e sete sistemas produtores integrados (Cantareira, Alto Tietê, Guarapiranga, Cotia, Rio Grande, Rio Claro e São Lourenço), a metrópole vive um paradoxo entre abundância pluviométrica histórica e escassez aguda recorrente (MARENGO et al., 2015; SABESP, 2024).

A crise de 2014-2015, deflagrada por bloqueio anômalo do Anticiclone Subtropical do Atlântico Sul (ASAS), levou o Sistema Cantareira ao chamado volume morto, expondo a fragilidade de uma infraestrutura projetada sobre premissas climáticas do século XX. Recaídas em 2017 e 2021 mostram que o fenômeno não é anomalia isolada, mas sintoma de transformação estrutural do regime hidroclimático regional (NOBRE et al., 2016; COELHO et al., 2016).

Tecnologicamente, há uma desconexão funcional persistente: APIs meteorológicas como o OpenWeather fornecem dados precisos de curto prazo, enquanto instituições governamentais, como a Agência Nacional de Águas e Saneamento Básico (ANA), o Departamento de Águas e Energia Elétrica (DAEE) e o Instituto Nacional de Meteorologia (INMET), mantêm bancos históricos em formatos heterogêneos. Paralelamente, LLMs comerciais sofrem de alucinação quando não há ancoragem em fontes verificáveis (JI et al., 2023). Havia, portanto, oportunidade científica clara: unificar essas fontes em uma plataforma única que transformasse dados brutos em inteligência acionável.

1.3 Apresentação da problemática

A problemática pode ser sintetizada na seguinte questão: como mitigar a incerteza na interpretação de dados climáticos e hidrológicos para prever, com maior precisão e contexto, riscos de escassez hídrica em curto e médio prazo na Macrometrópole Paulista?

Três subproblemas articulam a questão. Primeiro, sistemas tradicionais respondem quanto vai chover, mas falham em traduzir o impacto dessa precipitação no balanço hídrico dos reservatórios, sendo acurados, porém semanticamente pobres para o tomador de decisão. Segundo, LLMs comerciais usados isoladamente produzem imprecisões graves em análise numérica, por dificuldade aritmética em séries longas e ausência de ancoragem factual (BENDER et al., 2021). Terceiro, modelos clássicos como o ARIMA não capturam não linearidades nem dependências de longo prazo em regimes não estacionários (KRATZERT et al., 2018).

A hipótese central verificada foi a de que uma arquitetura híbrida — aprendizado profundo para a tarefa quantitativa (previsão de volume) e ensemble de LLMs para a tarefa qualitativa (interpretação) — pode superar abordagens isoladas, tanto em precisão estatística quanto em utilidade prática.

1.4 Delimitação da pesquisa e definição dos objetivos

A pesquisa delimitou-se ao desenvolvimento de um protótipo funcional, com escopo geográfico restrito à Macrometrópole Paulista e seus sete sistemas produtores. O recorte temporal abrange 26 anos (2000-2026), suficiente para capturar ao menos dois ciclos completos de El Niño e La Niña (NOAA, 2024).

Objetivo geral: desenvolver o HydraIA, plataforma de software que unifique previsão meteorológica, previsão hidrológica via aprendizado profundo e análise qualitativa de risco hídrico via ensemble de LLMs, produzindo relatórios com grau de confiança quantificado por validação cruzada.

Objetivos específicos:

a) consolidar fontes heterogêneas em um pipeline ETL único (SABESP, OpenWeather, DAEE, ANA);

b) treinar e validar uma rede HydroLSTM (256 unidades ocultas, dropout de 0,25) para prever o volume útil dos reservatórios em horizonte de 7 a 30 dias, com janela retrospectiva de 90 dias;

c) implementar uma camada de IA híbrida (edge-cloud) que orquestre três LLMs: Gemini 2.5 Pro (hidrológico), GPT (meteorológico) e Mistral 7B (sintetizador local em GPU NVIDIA RTX 3060);

d) implementar um algoritmo de validação cruzada que detecte convergências e divergências entre os especialistas e ajuste a confiança do relatório em função do delta apurado;

e) validar empiricamente o protótipo com suíte de testes unitários e comparar as previsões com dados reais observados, usando MAE e RMSE;

f) documentar o sistema seguindo princípios SOLID, garantindo extensibilidade para inclusão futura de novos LLMs sem alteração do orquestrador.

1.5 Apresentação da relevância do tema

A relevância manifesta-se em três dimensões. Socialmente, o HydraIA democratiza o acesso à informação de segurança hídrica em uma das regiões mais populosas do hemisfério sul, permitindo que gestores, agricultores e cidadãos antecipem cenários de crise (DI GIULIO et al., 2018; JACOBI et al., 2015). Tecnologicamente, propõe uma arquitetura que reduz custo e dependência de nuvem ao deslocar processamento para um modelo local quantizado, alinhando-se ao paradigma de Edge AI (PATTERSON et al., 2021). Cientificamente, contribui ao formalizar a validação cruzada entre LLMs heterogêneos como mecanismo de mitigação de alucinações em domínios técnicos (WANG et al., 2023).

2 MÉTODO DE PESQUISA

2.1 Tipo de investigação adotada

Quanto à natureza, a pesquisa é aplicada, dirigida à solução de um problema específico (GIL, 2017). Quanto à abordagem, é mista: quantitativa na modelagem das séries temporais e nas métricas de erro; qualitativa na avaliação dos relatórios produzidos pelos LLMs. Quanto aos objetivos, é exploratória, descritiva e explicativa. Quanto aos procedimentos, adotou-se a Pesquisa Experimental, fundada em prototipagem iterativa e simulação controlada de cenários hidrológicos, complementada por Pesquisa Bibliográfica e Documental (LAKATOS; MARCONI, 2017).

2.2 Definição da estratégia de coleta de dados

A coleta articulou três fontes complementares segundo a dimensão temporal. Dados históricos: 26 anos de séries diárias da API SABESP (volume útil, precipitação e vazões dos sete sistemas), persistidos em JSON, com novas tentativas (retry) e espera exponencial (backoff) em caso de falha. Dados

meteorológicos: previsões de oito dias do OpenWeather One Call 3.0 (temperatura, umidade, precipitação e probabilidade de chuva), com cache local de uma hora. Estado em tempo real: consulta diária ao endpoint /api/v4/dados/ultima-data da SABESP, seguida da coleta do resumo diário oficial dos sete sistemas, complementada pela projeção do HydroLSTM.

Adotou-se uma estratégia fail-fast: o pipeline recusa a execução se a API da SABESP não responder, garantindo que nenhum relatório seja produzido a partir de dados simulados; a indisponibilidade do OpenWeather, por sua vez, é tratada como dado opcional e não bloqueia o processamento.

2.3 Definição da estratégia de análise de dados

A análise seguiu quatro estágios. Pré-processamento: limpeza, normalização (StandardScaler) e estatísticas descritivas via Pandas, contornando a limitação da janela de contexto dos LLMs (LIU et al., 2023). Inferência via aprendizado profundo: o HydroLSTM (PyTorch 2.7, CUDA 11.8) recebe 39 variáveis de entrada e prevê o volume útil de seis sistemas-alvo. Análise qualitativa: em execução paralela (ThreadPoolExecutor), dois LLMs especialistas (Gemini 2.5 Pro, hidrológico; GPT, meteorológico) retornam JSON estruturado com nível de risco, tendência, análise e percentual de confiança. Validação cruzada: convergência bonifica a confiança em 15%; divergência penaliza 10% por ponto de delta; o modo parcial penaliza 30%; o risco final adota o maior entre os dois (princípio conservador); por fim, o Mistral 7B local sintetiza o relatório em português.

A validação empírica do modelo de séries temporais utilizou divisão temporal (treino, validação e teste, sem embaralhamento) e as métricas MAE e RMSE, usuais na avaliação de modelos hidrológicos (NASH; SUTCLIFFE, 1970; MORIASI et al., 2007). A validação do software utilizou testes unitários e de integração automatizados com o framework pytest, com dublês de teste (mocks) para as APIs externas.

3 REFERENCIAL TEÓRICO

O referencial articula-se em cinco pilares, progredindo do fenômeno físico ao artefato computacional: (i) a crise hídrica na Macrometrópole como fenômeno multidimensional; (ii) a modelagem de séries temporais hidrológicas com aprendizado profundo; (iii) os LLMs aplicados a domínios técnicos; (iv) os sistemas

multiagente e a validação cruzada; e (v) o Edge AI e as arquiteturas híbridas. A articulação justifica as escolhas técnicas do HydraIA e o situa no estado da arte.

3.1 A crise hídrica como fenômeno multidimensional

A RMSP vive um paradoxo hidrológico estrutural. Assentada em clima subtropical úmido sob influência da Zona de Convergência do Atlântico Sul (ZCAS), a metrópole construiu sua infraestrutura sobre a premissa da abundância. Os registros de 1900 a 2025 revelam que essa percepção é ilusória, mascarando uma vulnerabilidade sistêmica agravada nas últimas décadas (NOBRE et al., 2016; MARENGO et al., 2015). A adução na RMSP, iniciada em 1875 com a Companhia Cantareira, evoluiu para um sistema complexo cuja capacidade nominal, somados os sete sistemas produtores, é de cerca de 80 m³/s, suficiente para 22 milhões de habitantes em condições normais (SABESP, 2024; ANA, 2023).

O histórico documenta três episódios críticos no século XXI: a crise de 2003-2004 (Cantareira a 38%), a crise sistêmica de 2014-2015 (volume morto, atingindo -23% em fevereiro de 2015) e a recaída de 2020-2021 (níveis inferiores a 30%). Segundo Marengo et al. (2015) e Coelho et al. (2016), não são anomalias isoladas, mas manifestações de uma transformação estrutural do ciclo hidrológico regional. A crise de 2014-2015 evidenciou três fragilidades: obsolescência dos parâmetros de projeto, gestão reativa e comunicação tardia aos tomadores de decisão (JACOBI et al., 2015; DI GIULIO et al., 2018).

A variabilidade da precipitação no Sudeste responde a padrões de circulação atmosférica e teleconexões oceânicas, com destaque para o ASAS, a ZCAS, o ENSO e a Oscilação Decadal do Pacífico (CAVALCANTI; AMBRIZZI, 2009; INMET, 2024). A crise de 2014-2015 é um estudo de caso sinótico: no verão austral de 2014, um bloqueio anômalo do ASAS atuou como barreira troposférica, impedindo o avanço de frentes frias e a formação da ZCAS. Reanálises indicam pressão em torno de 1020 hPa por quase cinco semanas seguidas entre janeiro e fevereiro de 2014, persistência sem paralelo em cinco décadas (COELHO et al., 2016). O resultado foi o desvio do ar úmido para latitudes maiores, deixando o Sudeste sob subsidência, com temperaturas de 1 °C a 2 °C acima da climatologia e evaporação intensificada nos reservatórios.

Fator frequentemente subestimado é a dependência da Macrometrópole em relação à umidade importada da Bacia Amazônica. Os chamados Rios Voadores

correspondem ao transporte massivo de vapor d'água pelos Jatos de Baixos Níveis que, barrados pelos Andes, defletem para o sul e o sudeste, com fluxo entre 115 e 267 mil metros cúbicos por segundo, comparável à vazão do Rio Amazonas (NOBRE, 2014). A integridade desse sistema depende da floresta: estima-se que 74% da redução de pluviosidade e 16% do aquecimento amazônico na estação seca decorram da perda de cobertura florestal (MARENGO et al., 2018).

Por fim, a crise hídrica não é apenas falta de chuva vinda de fora: é também modificação local da atmosfera pela mancha urbana (LOMBARDO, 1985; FREITAS et al., 2007). A substituição da vegetação por concreto altera o balanço de energia na superfície, gerando uma Ilha de Calor Urbana intensa, cujo impacto é paradoxal: o aquecimento intensifica tempestades convectivas, mas suprime a chuva estratiforme de longa duração, justamente a que recarrega os mananciais (SILVA DIAS et al., 2013).

3.2 Modelagem de séries temporais hidrológicas com aprendizado profundo

A modelagem hidrológica tradicional baseia-se em modelos lineares (ARIMA, SARIMA, regressões) e em modelos conceituais físico-hidrológicos como o SAC-SMA e o IPH-II (TUCCI, 2005). Satisfatórios em cenários estacionários, esses modelos têm sua aplicabilidade erodida em regimes não estacionários decorrentes das mudanças climáticas (MILLY et al., 2008): a hipótese de estacionariedade é inadequada à intensificação de extremos, os modelos lineares capturam insuficientemente dependências de longo prazo e a multiplicidade de sazonalidades exige parâmetros excessivos, levando ao sobreajuste.

As redes neurais recorrentes, propostas por Elman (1990), modelam a dimensão temporal por conexões cíclicas, mas sofrem do desvanecimento de gradiente: os gradientes decaem exponencialmente na retropropagação através do tempo, impedindo o aprendizado de dependências longas (BENGIO et al., 1994). A arquitetura Long Short-Term Memory, de Hochreiter e Schmidhuber (1997), supera essa limitação com uma célula de memória controlada por três portões (entrada, esquecimento e saída) que regulam, de forma diferenciável, o fluxo de informação. Variantes como a GRU (CHO et al., 2014) ampliaram o espectro de aplicações.

O trabalho seminal de Kratzert et al. (2018, 2019) demonstrou que LSTMs superam modelos hidrológicos conceituais, incluindo o SAC-SMA, mesmo em bacias não vistas no treinamento, o que catalisou a pesquisa em hidrologia profunda

aplicada a reservatórios, cheias e detecção de anomalias. Revisões recentes (SHEN, 2018; XU; LIANG, 2022) consolidam que LSTMs superam modelos lineares em regimes não estacionários e que o pré-processamento tem impacto comparável ao da arquitetura. O HydraIA insere-se nessa tradição, aplicado ao Cantareira e aos demais sistemas da Macrometrópole, com janela de 90 dias, horizonte de 30 dias, 256 unidades ocultas e dropout de 0,25 calibrados empiricamente.

3.3 Modelos de Linguagem de Grande Escala em domínios técnicos

A revolução contemporânea em processamento de linguagem natural fundamenta-se na arquitetura Transformer (VASWANI et al., 2017), que emprega autoatenção para computar em paralelo as relações entre todos os tokens, viabilizando o treinamento paralelizado em GPUs e a captura de dependências de longo alcance. Sobre esse substrato surgiram três famílias: encoder-only, como o BERT (DEVLIN et al., 2019); decoder-only, como o GPT (BROWN et al., 2020); e encoder-decoder, como o T5 (RAFFEL et al., 2020). Os LLMs comerciais do HydraIA pertencem à segunda família. Para execução local, destaca-se o Mistral 7B Instruct v0.3 (JIANG et al., 2023), que usa Grouped-Query Attention e Sliding Window Attention; sua quantização em formato GGUF permite a execução em GPUs com 8 a 12 GB de VRAM.

LLMs tendem a gerar conteúdo factualmente incorreto com alta confiança aparente, fenômeno conhecido como alucinação. Ji et al. (2023) distinguem alucinações intrínsecas (contradições com a entrada) e extrínsecas (afirmações não verificáveis); Bender et al. (2021) caracterizam LLMs como papagaios estocásticos, capazes de gerar texto plausível sem garantia factual. No domínio hidrológico, as implicações são graves: consultado sobre o histórico do Cantareira, um LLM pode produzir valores verossímeis sem correspondência com os registros oficiais. As mitigações incluem RLHF (OUYANG et al., 2022), chain-of-thought (WEI et al., 2022), self-consistency (WANG et al., 2023) e a Retrieval-Augmented Generation (RAG).

A RAG, formalizada por Lewis et al. (2020), é o estado da arte para mitigar alucinações ao desacoplar o conhecimento factual (base externa) da capacidade linguística (parâmetros). O HydraIA adota a variante aqui denominada compressão estatística: as séries históricas brutas são pré-processadas em Python/Pandas, gerando um resumo estatístico estruturado que se torna o documento injetado no

contexto dos LLMs. A abordagem reduz tokens, move a aritmética para o Python (determinístico) e garante reprodutibilidade independentemente da temperatura do modelo.

3.4 Sistemas multiagente e validação cruzada

A noção de que múltiplos modelos heterogêneos superam qualquer modelo isolado tem raízes na teoria de ensemble: bagging, boosting e stacking (BREIMAN, 1996, 2001). Erros idiossincráticos cancelam-se quando agregados, desde que descorrelacionados. Em LLMs, Wang et al. (2023) mostram que a self-consistency melhora o raciocínio matemático; Du et al. (2023) propõem uma sociedade de mentes, com agentes que debatem até convergir; e Yang et al. (2024) revisam o campo emergente de LLM-as-a-Judge.

O HydraIA aplica esse paradigma em topologia hierárquica de duas camadas. Na primeira, dois LLMs comerciais (Gemini 2.5 Pro e GPT) atuam como especialistas independentes, com entradas parcialmente distintas (perspectiva hidrológica versus meteorológica) e saída em JSON estruturado. Na segunda, o Mistral 7B local atua como sintetizador. A inovação reside na validação cruzada quantificada, na qual o delta entre os níveis de risco dos especialistas é convertido em ajuste explícito do grau de confiança do relatório, conforme detalhado na seção 4.3.

3.5 Edge AI, computação local e arquiteturas híbridas

Edge AI refere-se à execução de modelos em dispositivos de borda, em oposição a data centers, motivada por latência, privacidade, custo e resiliência (CHEN; RAN, 2019; ZHANG et al., 2022). A viabilidade prática para LLMs surgiu em 2023 com técnicas de quantização que reduzem a precisão dos pesos para INT8, INT4 ou formatos como o GGUF, viabilizando modelos de 7 a 13 bilhões de parâmetros em GPUs de consumo (DETTMERS et al., 2022; FRANTAR et al., 2023). Ferramentas como LM Studio, Ollama e llama.cpp democratizaram o acesso a essa execução local.

O HydraIA adota uma arquitetura híbrida: coleta, pré-processamento (Pandas) e inferência de aprendizado de máquina (HydroLSTM em PyTorch+CUDA) operam em hardware local (RTX 3060 com 12 GB, Intel i5-13400F, 32 GB de RAM). A análise qualitativa é mista: dois especialistas em nuvem (Gemini e GPT) e um sintetizador local (Mistral 7B) que produz o relatório sem expor os dados brutos. Sob

a ótica de padrões de projeto, aplicam-se princípios SOLID: Strategy na camada LLM (cada especialista herda de uma classe abstrata), viabilizando a inclusão futura de modelos sem alterar o orquestrador; Template Method, que consolida retry e validação na superclasse; e Dependency Injection, que viabiliza testes com dublês, sem custos de API.

4 RESULTADOS OBTIDOS

4.1 Arquitetura implementada do pipeline

O HydraIA foi implementado em Python 3.11+ como um pipeline de quatro camadas sequenciais, ilustrado na Figura 1. Na camada de coleta, o módulo coletor consome a API v4 oficial dos mananciais da SABESP: primeiro obtém a data mais recente publicada (/api/v4/dados/ultima-data) e, em seguida, o resumo diário (/api/v4/sistemas/dados/resumo-diario/{data}) com volume útil, chuva e vazões dos sete sistemas da Macrometrópole, com três tentativas e espera entre elas. O coletor meteorológico obtém oito dias de previsão do OpenWeather One Call 3.0. Ambos contam com cache local de uma hora, com escrita atômica para resistir a falhas durante a gravação.

Na camada de previsão, o módulo de inferência carrega o modelo treinado e os últimos 90 dias de dados reais e projeta o volume útil percentual de seis sistemas para os 30 dias seguintes. Na camada de ensemble, executam-se as três fases descritas na seção 4.3. Na camada de saída, o relatório técnico é impresso no console e persistido em arquivo Markdown, acompanhado de um arquivo de metadados JSON com risco, confiança, data de referência e identificador de correlação da execução, o que garante rastreabilidade.

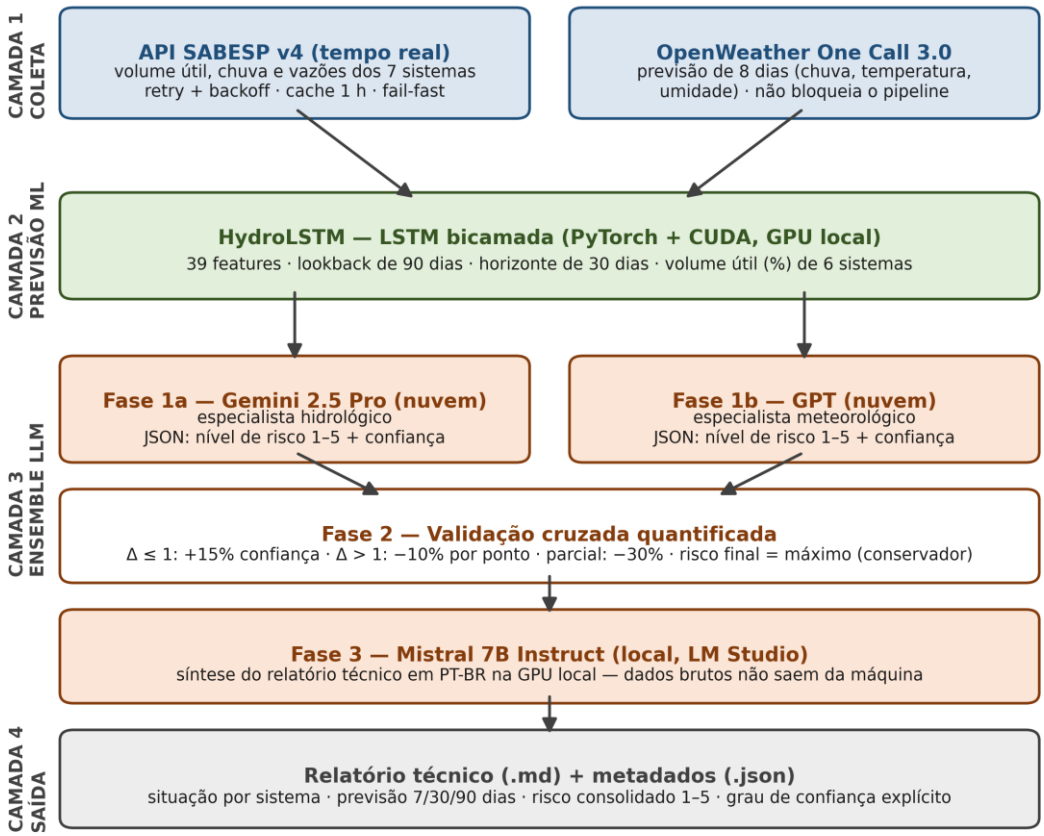


Figura 1 – Arquitetura em quatro camadas do pipeline HydraIA.
Fonte: Elaborado pelo autor (2026).

A camada de LLMs foi estruturada com o padrão Strategy: uma classe abstrata define o contrato do especialista e concentra, via Template Method, o esqueleto de chamada com novas tentativas, extração e validação do JSON de resposta; as subclasses concretas implementam apenas a invocação específica de cada provedor. O orquestrador recebe os especialistas por injeção de dependência, o que permitiu testá-lo integralmente com dublês, sem custos de API. Como demonstração do princípio aberto-fechado, a inclusão de um novo provedor de LLM exige apenas a criação de uma nova subclasse, sem alteração do orquestrador.

4.2 Preparação dos dados e treinamento do HydroLSTM

O conjunto de dados foi construído a partir dos registros históricos diários da SABESP entre 2000 e 2026, consolidados por um processo ETL que normaliza as séries (StandardScaler) e monta janelas deslizantes de 90 dias com 39 variáveis de entrada (volume útil, precipitação e vazões de todos os sistemas). A divisão treino/validação/teste foi estritamente temporal, sem embaralhamento, com testes automatizados dedicados a impedir vazamento de dados entre as partições. O

treinamento foi realizado em GPU NVIDIA RTX 3060 com PyTorch 2.7 e CUDA 11.8, com parada baseada no erro de validação. A Tabela 1 resume os hiperparâmetros e as métricas obtidas.

Tabela 1 – Hiperparâmetros e métricas do HydroLSTM.

Parâmetro	Valor
Arquitetura	LSTM bicamada (PyTorch)
Variáveis de entrada (features)	39
Variáveis-alvo	volume útil (%) de 6 sistemas
Janela retrospectiva (lookback)	90 dias
Horizonte de previsão	30 dias
Unidades ocultas / camadas	256 / 2
Dropout	0,25
MAE – validação / pp	0,35
MAE – teste / pp	6,05
RMSE – teste / pp	7,53

Fonte: Elaborado pelo autor (2026).

Como mostrado na Tabela 1, o erro absoluto médio (MAE) foi de 0,35 ponto percentual na partição de validação e de 6,05 pontos percentuais na partição de teste, com RMSE de 7,53. Além da previsão pontual, o sistema deriva quantis empíricos (p10, p50 e p90) e probabilidades de o volume útil cruzar limiares operacionais — P(<30%), P(<50%) e P(>80%) — a partir da distribuição histórica condicionada ao dia do ano, oferecendo ao gestor uma leitura probabilística e não apenas determinística.

4.3 Ensemble multi-LLM e validação cruzada quantificada

O ensemble executa em três fases. Na primeira, dois especialistas em nuvem analisam o mesmo cenário em paralelo sob perspectivas distintas: o Gemini 2.5 Pro recebe o estado atual dos reservatórios e a projeção do HydroLSTM (perspectiva hidrológica), e o GPT recebe adicionalmente a previsão meteorológica do OpenWeather (perspectiva meteorológica). Cada um retorna JSON estruturado com nível de risco na escala de 1 a 5, tendência, análise e percentual de confiança. Cada resposta passa por validação de esquema: o nível de risco deve ser inteiro entre 1 e 5 e o percentual de confiança é restringido ao intervalo de 0 a 100; respostas malformadas são descartadas após as tentativas de repetição.

Na segunda fase, o algoritmo de validação cruzada compara os níveis de risco dos dois especialistas e converte o delta em ajuste explícito do grau de confiança do

relatório, conforme as regras da Tabela 2. Na terceira fase, o Mistral 7B Instruct v0.3, executado localmente via LM Studio, recebe as duas análises e o veredito da validação cruzada — incluindo divergências, quando existentes — e sintetiza o relatório técnico final em português.

Tabela 2 – Regras da validação cruzada entre especialistas.

Cenário	Condição	Efeito sobre a confiança
Convergência	delta ≤ 1 ponto	bonificação de 15%
Divergência	delta > 1 ponto	penalização de 10% por ponto de delta
Parcial	apenas um especialista respondeu	penalização de 30%
Risco consolidado	qualquer cenário	adota-se o maior risco (princípio conservador)

Fonte: Elaborado pelo autor (2026).

4.4 Execuções com dados reais

O pipeline completo foi executado repetidamente com dados reais da SABESP entre abril e maio de 2026. Na execução de 13 de maio de 2026, o sistema coletou o resumo diário oficial, identificou o Cantareira com 41,42% de volume útil — 18,19 pontos percentuais abaixo da mediana histórica do mês, com escore-z de -0,58 — e média da Macrometrópole de 68,97%, sem sistemas abaixo do limiar crítico de 30%. A Tabela 3 apresenta o panorama por sistema produzido nessa execução.

Tabela 3 – Situação dos sistemas produtores em execução real do pipeline (13/05/2026).

Sistema	Volume útil / %	Delta vs. p50 do mês / pp	Anomalia (escore-z)
Cantareira	41,42	-18,19	-0,58
Alto Tietê	52,20	-6,75	-0,43
Guarapiranga	80,12	+2,57	+0,40
Cotia	62,15	-19,88	-0,86
Rio Grande	88,08	-3,72	-0,44
Rio Claro	62,16	-34,51	-0,97
São Lourenço	96,67	+37,06	n/d

Fonte: Elaborado pelo autor (2026), a partir de dados abertos da API SABESP.

O relatório sintetizado classificou o risco consolidado em 2 em uma escala de 5, apontou o Cantareira como o sistema mais vulnerável e produziu recomendações operacionais de curto prazo (monitoramento de precipitações e vazões, com foco em eficiência no uso da água) e de médio prazo (preparação para redução gradual dos volumes). Nessa execução, apenas um especialista em nuvem respondeu dentro do prazo, e o mecanismo de modo parcial penalizou a confiança do relatório para 57%,

registrando explicitamente a limitação no próprio texto — comportamento desejado do princípio conservador. A síntese local pelo Mistral 7B na GPU RTX 3060 apresentou latência de 15 a 30 segundos por relatório.

4.5 Qualidade de software e reprodutibilidade

A qualidade do protótipo foi sustentada por uma suíte de 265 casos de teste automatizados (pytest), cobrindo o coletor SABESP (interpretação de respostas, novas tentativas, mapeamento de identificadores), o orquestrador (extração e validação de JSON, regras de validação cruzada), os especialistas LLM (repetição, recuo de parâmetros não suportados), o cache atômico (expiração, recuperação de corrupção), os modelos de referência (baselines), a semente determinística e a validação semântica das saídas. Ao final do desenvolvimento, o subconjunto que cobre os módulos centrais — 81 testes — foi executado integralmente com aprovação. Completam a infraestrutura a observabilidade com identificador de correlação por execução, um disjuntor (circuit breaker) para integrações instáveis e um controle de orçamento de chamadas às APIs pagas.

5 ANÁLISES E DISCUSSÕES

5.1 Desempenho preditivo e não estacionariedade

A diferença entre o MAE de validação (0,35 pp) e o de teste (6,05 pp) é o resultado empírico mais instrutivo do trabalho. Como a divisão é temporal, a partição de teste corresponde ao período mais recente da série — justamente aquele em que o regime hidroclimático mais se afasta do histórico de treinamento. A degradação observada corrobora, na prática, a tese da morte da estacionariedade (MILLY et al., 2008) e a transformação estrutural do regime regional descrita por Marengo et al. (2015): o modelo aprende muito bem o passado, mas o futuro recente deixou de se parecer com ele. Ainda assim, um erro médio da ordem de 6 pontos percentuais em horizonte de 30 dias permanece informativo para a gestão, e os resultados são compatíveis com a literatura que aponta vantagem das LSTMs sobre abordagens lineares em regimes não estacionários (KRATZERT et al., 2018; SHEN, 2018).

A limitação mais visível da previsão é o achatamento das trajetórias em janelas curtas: nas execuções reais, a mediana prevista manteve-se praticamente constante ao longo dos sete primeiros dias. O comportamento é típico de modelos treinados para minimizar o erro médio em horizontes longos, que tendem a respostas suaves. A complementação com quantis empíricos e probabilidades de cruzamento de

limiares atenua o problema ao explicitar a incerteza, mas a calibração fina do horizonte curto permanece como trabalho futuro.

5.2 Validação cruzada como medida de incerteza

O delta entre especialistas mostrou-se um indicador útil de incerteza epistêmica. Em execução real com apenas um especialista disponível, o modo parcial reduziu a confiança para 57% e registrou o fato no relatório — exatamente o comportamento que distingue o HydraIA de um agregador ingênuo de respostas de LLMs. O resultado dialoga com a literatura de self-consistency (WANG et al., 2023) e de debate multiagente (DU et al., 2023), mas com uma diferença de engenharia: o ajuste de confiança é determinístico, auditável e aplicado fora dos modelos, e o risco final adota sempre o maior valor entre os especialistas, alinhando-se à aversão ao risco da gestão pública de recursos hídricos.

5.3 Custo, privacidade e viabilidade do Edge AI

A estratégia de compressão estatística reduziu o consumo de tokens dos LLMs em mais de 90% em relação ao envio das séries brutas, viabilizando a operação dentro da janela de contexto do modelo local e reduzindo o custo das chamadas em nuvem. Igualmente relevante, a aritmética permanece no Python: o LLM interpreta resultados pré-calculados, e o prompt proíbe a geração de números ausentes do contexto, mitigando a alucinação numérica apontada por Ji et al. (2023) e Bender et al. (2021). A síntese final pelo Mistral 7B na GPU local, com latência de 15 a 30 segundos e custo zero por token, confirma a viabilidade do paradigma de Edge AI com quantização (DETTMERS et al., 2022) em hardware de consumo, com o benefício adicional de privacidade: os dados brutos não saem da máquina.

5.4 Limitações do trabalho

Cinco limitações merecem registro. Primeira, a dependência da disponibilidade da API da SABESP: por decisão de projeto (fail-fast), o pipeline não produz relatório sem dados reais. Segunda, o modelo não incorpora variáveis exógenas de teleconexão (como os índices ONI e TSA) nem a umidade amazônica discutida na seção 3.1, candidatas naturais a novas variáveis de entrada. Terceira, o achatamento da previsão em horizonte curto, já discutido. Quarta, a avaliação da qualidade textual dos relatórios ainda não foi sistematizada com painel de especialistas humanos, permanecendo qualitativa. Quinta, os LLMs em nuvem mudam de comportamento entre versões — durante o desenvolvimento, modelos de

nova geração deixaram de aceitar o parâmetro de temperatura, exigindo tratamento defensivo —, o que recomenda o desacoplamento por configuração adotado no projeto.

6 CONSIDERAÇÕES FINAIS

Este trabalho desenvolveu e validou o HydraIA, plataforma que unifica coleta de dados oficiais em tempo real, previsão hidrológica por aprendizado profundo e interpretação qualitativa por ensemble de LLMs com validação cruzada quantificada. O objetivo geral foi atingido: o protótipo funcional produz, a partir de dados reais da SABESP, relatórios técnicos de risco hídrico com grau de confiança explícito, classificando o risco em escala de cinco pontos.

Os objetivos específicos foram contemplados: o pipeline ETL consolidou as fontes heterogêneas; o HydroLSTM foi treinado em 26 anos de séries e avaliado com MAE de 0,35 pp na validação e 6,05 pp no teste; a camada híbrida edge-cloud orquestrou Gemini 2.5 Pro, GPT e Mistral 7B; o algoritmo de validação cruzada converteu convergências e divergências em ajustes auditáveis de confiança; a suíte de 265 casos de teste sustentou a qualidade do software, com os 81 testes dos módulos centrais aprovados ao final do desenvolvimento; e a arquitetura SOLID garantiu extensibilidade comprovada pelo uso de injeção de dependência e do padrão Strategy.

As contribuições principais são três: a formalização da validação cruzada quantificada entre LLMs heterogêneos como mecanismo auditável de estimativa de incerteza; a demonstração de que uma arquitetura híbrida local-nuvem, com compressão estatística e síntese em GPU de consumo, reduz drasticamente custo e exposição de dados; e a disponibilização de um pipeline reprodutível, construído exclusivamente sobre dados públicos, aplicável a outros sistemas metropolitanos de abastecimento.

Como continuidade da pesquisa, propõem-se: a migração do armazenamento para banco de dados de séries temporais; o desenvolvimento de um painel web para gestores e cidadãos; a incorporação de índices de teleconexão e de variáveis da umidade amazônica como entradas do modelo; a experimentação de arquiteturas Transformer para séries temporais em comparação com a LSTM; a avaliação sistemática dos relatórios por painel de especialistas humanos; e a calibração específica do horizonte curto de previsão.

7 REFERÊNCIAS

AGÊNCIA NACIONAL DE ÁGUAS E SANEAMENTO BÁSICO (ANA). **Dados de operação dos reservatórios – Sistema Cantareira**. Brasília, 2023. Disponível em: https://www.gov.br/ana. Acesso em: 12 ago. 2025.

BENDER, E. M.; GEBRU, T.; McMILLAN-MAJOR, A.; SHMITCHELL, S. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? In: **FAccT '21**, 2021, p. 610-623.

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157-166, 1994.

BREIMAN, L. Bagging predictors. **Machine Learning**, v. 24, n. 2, p. 123-140, 1996.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5-32, 2001.

BROWN, T. B. et al. Language Models are Few-Shot Learners. In: **NeurIPS**, v. 33, 2020.

CAVALCANTI, I. F. A.; AMBRIZZI, T. Teleconexões e suas influências no Brasil. In: CAVALCANTI, I. F. A. et al. (org.). **Tempo e Clima no Brasil**. São Paulo: Oficina de Textos, 2009. cap. 19.

CHEN, J.; RAN, X. Deep Learning With Edge Computing: A Review. **Proceedings of the IEEE**, v. 107, n. 8, p. 1655-1674, 2019.

CHO, K. et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. In: **EMNLP**, 2014.

COELHO, C. A. S.; CARDOSO, D. H. F.; FIRPO, M. A. F. Precipitation diagnostics of an exceptionally dry event in São Paulo, Brazil. **Theoretical and Applied Climatology**, v. 125, n. 3-4, p. 769-784, 2016.

DETTMERS, T.; LEWIS, M.; BELKADA, Y.; ZETTLEMOYER, L. LLM.int8(): 8-bit Matrix Multiplication for Transformers at Scale. In: **NeurIPS**, 2022.

DEVLIN, J.; CHANG, M.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: **NAACL-HLT**, 2019.

DI GIULIO, G. M. et al. Mainstreaming climate adaptation in the megacity of São Paulo, Brazil. **Cities**, v. 72, p. 237-244, 2018.

DU, Y. et al. Improving Factuality and Reasoning in Language Models through Multiagent Debate. **arXiv preprint** arXiv:2305.14325, 2023.

ELMAN, J. L. Finding structure in time. **Cognitive Science**, v. 14, n. 2, p. 179-211, 1990.

FRANTAR, E. et al. GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers. In: **ICLR**, 2023.

FREITAS, E. D. et al. Interactions of an urban heat island and sea-breeze circulations during winter over the metropolitan area of São Paulo. **Boundary-Layer Meteorology**, v. 122, n. 1, p. 43-65, 2007.

GIL, A. C. **Como Elaborar Projetos de Pesquisa**. 6. ed. São Paulo: Atlas, 2017.

HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. **Neural Computation**, v. 9, n. 8, p. 1735-1780, 1997.

INSTITUTO NACIONAL DE METEOROLOGIA (INMET). **BDMEP – Banco de Dados Meteorológicos para Ensino e Pesquisa**. Brasília, 2024. Disponível em: https://portal.inmet.gov.br. Acesso em: 30 out. 2025.

JACOBI, P. R.; CIBIM, J.; LEÃO, R. S. Crise hídrica na Macrometrópole Paulista e respostas da sociedade civil. **Estudos Avançados**, v. 29, n. 84, p. 27-42, 2015.

JI, Z. et al. Survey of Hallucination in Natural Language Generation. **ACM Computing Surveys**, v. 55, n. 12, p. 1-38, 2023.

JIANG, A. Q. et al. Mistral 7B. **arXiv preprint** arXiv:2310.06825, 2023.

KRATZERT, F. et al. Rainfall-runoff modelling using Long Short-Term Memory (LSTM) networks. **Hydrology and Earth System Sciences**, v. 22, n. 11, p. 6005-6022, 2018.

KRATZERT, F. et al. Towards learning universal, regional, and local hydrological behaviors via machine learning applied to large-sample datasets. **Hydrology and Earth System Sciences**, v. 23, n. 12, p. 5089-5110, 2019.

LAKATOS, E. M.; MARCONI, M. A. **Fundamentos de Metodologia Científica**. 8. ed. São Paulo: Atlas, 2017.

LEWIS, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: **NeurIPS**, 2020.

LIU, N. F. et al. Lost in the Middle: How Language Models Use Long Contexts. **TACL**, 2023.

LOMBARDO, M. A. **Ilha de calor nas metrópoles: o exemplo de São Paulo**. São Paulo: HUCITEC, 1985.

MARENGO, J. A. et al. A seca e a crise hídrica de 2014-2015 em São Paulo. **Revista USP**, n. 106, p. 31-44, 2015.

MARENGO, J. A. et al. Changes in climate and land use over the Amazon region. **Frontiers in Earth Science**, v. 6, art. 228, 2018.

MILLY, P. C. D. et al. Stationarity is dead: whither water management? **Science**, v. 319, n. 5863, p. 573-574, 2008.

MORIASI, D. N. et al. Model evaluation guidelines for systematic quantification of accuracy in watershed simulations. **Transactions of the ASABE**, v. 50, n. 3, p. 885-900, 2007.

NASH, J. E.; SUTCLIFFE, J. V. River flow forecasting through conceptual models part I. **Journal of Hydrology**, v. 10, n. 3, p. 282-290, 1970.

NOAA – National Oceanic and Atmospheric Administration. **Climate Variability: Oceanic Niño Index**. 2024. Disponível em: https://www.climate.gov. Acesso em: 06 set. 2025.

NOBRE, A. D. **O futuro climático da Amazônia: relatório de avaliação científica**. São José dos Campos: ARA / CCST-INPE, 2014.

NOBRE, C. A. et al. Land-use and climate change risks in the Amazon and the need of a novel sustainable development paradigm. **PNAS**, v. 113, n. 39, p. 10759-10768, 2016.

OUYANG, L. et al. Training language models to follow instructions with human feedback. In: **NeurIPS**, 2022.

PATTERSON, D. et al. Carbon Emissions and Large Neural Network Training. **arXiv preprint** arXiv:2104.10350, 2021.

RAFFEL, C. et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. **JMLR**, v. 21, n. 140, p. 1-67, 2020.

SABESP. **Sistema Cantareira – Portal dos Mananciais**. 2024. Disponível em: https://mananciais.sabesp.com.br. Acesso em: 05 nov. 2025.

SHEN, C. A Transdisciplinary Review of Deep Learning Research and Its Relevance for Water Resources Scientists. **Water Resources Research**, v. 54, n. 11, p. 8558-8593, 2018.

SILVA DIAS, M. A. F. et al. Changes in extreme daily rainfall for São Paulo, Brazil. **Climatic Change**, v. 116, n. 3-4, p. 705-722, 2013.

TUCCI, C. E. M. **Modelos Hidrológicos**. 2. ed. Porto Alegre: Editora da UFRGS, 2005.

VASWANI, A. et al. Attention Is All You Need. In: **NeurIPS**, 2017.

WANG, X. et al. Self-Consistency Improves Chain of Thought Reasoning in Language Models. In: **ICLR**, 2023.

WEI, J. et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. In: **NeurIPS**, 2022.

XU, T.; LIANG, F. Machine learning for hydrologic sciences: An introductory overview. **WIREs Water**, v. 9, n. 5, e1533, 2022.

YANG, K. et al. LLM-as-a-Judge: A Survey on Evaluation of Large Language Models. **arXiv preprint** arXiv:2411.15594, 2024.

ZHANG, X. et al. A Survey on Edge Intelligence. **IEEE Internet of Things Journal**, v. 9, n. 24, p. 23950-23972, 2022.